ORGANISATION D'ÉQUIPE / VERSION DE DÉMARRAGE

Un projet complet. Trois responsabilités équilibrées.

Ilyes · Hani · Moughit

Plan de travail du mini-projet de fouille de données

Ce que vous devez produire
Une analyse de données, une comparaison des modèles obligatoires, une application interactive locale, un rapport scientifique et un dépôt GitHub public avec des contributions personnelles.

Membre	Responsabilité principale	Part de modélisation
Ilyes	Données, statistiques et dashboard d'exploration	Zero-R + Naïve Bayes
Hani	Prétraitement et protocole d'évaluation	K-NN + SVM
Moughit	Application et intégration des résultats	Arbre de décision + Random Forest

Hypothèses de ce plan

Le parcours n'étant pas encore confirmé, les pages 2 à 11 détaillent une **classification supervisée**. Si vous choisissez le clustering, appliquez les remplacements de la page 12. Vous ne devez pas réaliser les deux parcours.

Le calendrier proposé dure **4 semaines**, pour environ **48 heures de travail par personne**. Ce sont des estimations d'organisation, pas des exigences du professeur. Les temps de calcul automatiques ne sont pas comptés comme du travail actif.

Comment utiliser le document

Pages 2 à 5 : répartition et fiches individuelles. **Pages 6 à 8 :** étapes, méthode et calendrier. **Pages 9 à 11 :** application, dépôt et validation finale. **Page 12 :** variante non supervisée.

Document interne avec vos prénoms
Pour le dépôt, les notebooks, le code, le README et le rapport publics, remplacez les prénoms par vos vrais codes étudiants. Ne publiez pas ce plan nominatif tel quel.

PLAN DE TRAVAIL / 02

Répartir l'effort équitablement

Chacun réalise du code, des expériences, de l'intégration, de la rédaction et une relecture.

Bloc de travail	Ilyes	Hani	Moughit
Cadrage commun, choix du dataset et installation	3 h	3 h	3 h
Bloc technique principal	14 h	14 h	14 h
Modèles attribués, réglage et interprétation	7 h	11 h	9 h
Bloc complémentaire	11 h	7 h	9 h
Ses sections du rapport et du README	6 h	6 h	6 h
Relecture croisée et recette commune	7 h	7 h	7 h
Total indicatif	**48 h**	**48 h**	**48 h**

Pourquoi cette répartition est équitable

Zero-R est simple : Ilyes prend donc davantage de travail sur les données et les statistiques. Hani porte les réglages K-NN/SVM et le protocole commun. Moughit développe l'application, mais Ilyes construit le dashboard et Hani fournit la fonction de prédiction prête à intégrer.

Blocs principaux : Ilyes réalise l'audit, le nettoyage et les analyses statistiques ; Hani construit le pipeline et le protocole ; Moughit développe la structure, le formulaire et l'intégration. **Blocs complémentaires :** EDA et coordination pour Ilyes, fonction de prédiction pour Hani, comparaison et reproductibilité pour Moughit.

Responsable ne signifie pas « seul »

Production	Auteur responsable	Relecteur principal
Données, statistiques, Zero-R et Naïve Bayes	Ilyes	Hani
Prétraitement, protocole, K-NN et SVM	Hani	Moughit
Application, arbre et Random Forest	Moughit	Ilyes

Règle d'ajustement chaque semaine
Notez le temps actif réel. Si un membre dépasse sa prévision de plus de 3 heures, déplacez une tâche autonome vers un autre membre. On équilibre le travail réel, pas le nombre de lignes de code ni le nombre de commits.

Coordination proposée : Ilyes centralise les décisions et le suivi. Le rôle de chef de groupe doit être confirmé ensemble ; il ne donne pas la responsabilité de réaliser le travail des autres.

PLAN DE TRAVAIL / 03

Ilyes : données, analyses et EDA

Ta mission : rendre les données compréhensibles et produire les preuves qui justifient leur préparation.

01 Vérifier et documenter le dataset

Après le choix collectif, relève la source, le nombre de lignes brutes et le nombre d'attributs. Vérifie le minimum de 10 000 observations valides et 10 attributs. Décris la cible, les unités, les catégories et les variables qui seraient inconnues au moment de prédire.

Livraison : Une fiche de données et un dictionnaire des colonnes ; les données brutes restent intactes dans data/raw/.

02 Faire l'audit et le nettoyage de base

Repère les types incorrects, doublons accidentels, valeurs impossibles et catégories incohérentes. Propose une règle justifiée pour chaque problème et compte les lignes concernées. Hani réalise ensuite la séparation ; les médianes et seuils appris seront calculés dans son pipeline.

Livraison : Les fonctions de nettoyage et le notebook 01 ; Hani doit pouvoir reproduire les corrections.

03 Explorer et réaliser au moins deux analyses statistiques

Sur l'entraînement, décris distributions, valeurs manquantes, fréquences et corrélations. Choisis deux questions utiles et des tests adaptés aux variables : par exemple une association entre catégories ou une comparaison entre groupes. Vérifie leurs conditions et interprète les résultats réels.

Livraison : Pour chaque analyse : question, H0, méthode, justification, conditions, statistique, p-value et conclusion ; ampleur de l'effet si pertinente.

04 Prendre en charge Zero-R et Naïve Bayes

Utilise le protocole fourni par Hani. Zero-R prédit la classe majoritaire et n'a pas de recherche d'hyperparamètres. Pour Naïve Bayes, choisis une variante compatible avec les données, règle ses paramètres et explique l'hypothèse d'indépendance conditionnelle.

Livraison : Deux résultats au format commun, la recherche Naïve Bayes et un commentaire sur les erreurs.

05 Construire la vue d'exploration de l'application

Prépare les six éléments obligatoires : statistiques, valeurs manquantes, histogrammes et KDE, fréquences, heatmap de corrélation et filtre interactif. Fournis une vue que Moughit peut intégrer ; vérifie que les graphiques répondent au filtre.

Livraison : La vue EDA, ses fonctions de visualisation et quelques captures destinées au rapport.

06 Documenter, transmettre et relire

Rédige les sections données, nettoyage, EDA, statistiques et tes deux modèles. Mets à jour tes contributions. Relis l'application et les modèles de Moughit. Si tu es chef de groupe, centralise aussi les échanges officiels.

Livraison : Tes sections rédigées, tes commits personnels et les remarques de relecture.

Tu as terminé quand…
Hani comprend les colonnes sans te recontacter, le nettoyage est reproductible, deux analyses sont justifiées, tes modèles sont comparables aux autres et le dashboard fonctionne dans l'application.

PLAN DE TRAVAIL / 04

Hani : préparation et protocole ML

Ta mission : garantir que tous les modèles sont comparés correctement et que la prédiction utilise le même traitement qu'à l'entraînement.

01 Fixer une séparation commune

Après les corrections de base, réserve le test final et conserve les indices de séparation. Un partage 80/20 est un exemple. Utilise la stratification si les observations sont indépendantes ; si elles sont temporelles ou liées à un même individu, adapte la séparation et les plis.

Livraison : Une séparation identique pour tous, une graine fixée et une description claire du protocole.

02 Construire le prétraitement réutilisable

Sépare variables numériques et catégorielles. Prévois l'imputation, l'encodage et la standardisation utiles. Assemble les transformations avec ColumnTransformer puis un Pipeline. Les paramètres appris sont recalculés dans chaque pli, jamais sur tout le dataset avant validation.

Livraison : Le notebook 02 et src/preprocessing.py, avec les variantes nécessaires aux différentes familles de modèles.

03 Définir les expériences communes

Choisis avec l'équipe la métrique principale avant les réglages. Prépare une validation croisée à au moins cinq plis et un format identique pour les résultats. Fournis un exemple fonctionnel que les deux autres peuvent réutiliser avec leurs modèles.

Livraison : Un protocole écrit, la fonction d'évaluation commune et le schéma du tableau de résultats.

04 Entraîner et optimiser K-NN et SVM

Pour K-NN, étudie nombre de voisins, distance et pondération. Pour SVM, couvre les noyaux linéaire, RBF et polynomial, avec leurs paramètres adaptés. Utilise GridSearchCV ou RandomizedSearchCV ; conserve grille, scores moyens, variabilité et meilleurs paramètres.

Livraison : Deux pipelines réglés, leurs résultats et une explication des écarts entre entraînement et validation.

05 Fournir la fonction de prédiction à l'application

Écris dans src/models.py le chargement du pipeline retenu et la fonction qui reçoit une observation. Définis avec Ilyes les colonnes, types, unités et catégories autorisées. La fonction retourne la classe et, si disponible, une probabilité ou un score correctement nommé.

Livraison : Une fonction utilisable par Moughit sans refaire d'encodage, plus un exemple d'entrée valide.

06 Vérifier la méthode et rédiger

Relis les analyses et modèles d'Ilyes. Vérifie les cinq optimisations et l'absence de fuite de données. Rédige les sections prétraitement, protocole, K-NN/SVM et la lecture commune des métriques, avec les contributions des deux autres.

Livraison : Tes sections, les résultats consolidés avec Moughit et tes commits personnels.

Tu as terminé quand…
Les trois membres utilisent les mêmes observations et critères, les cinq modèles réglables sont optimisés, le test est resté réservé jusqu'au gel des choix et la prédiction recharge un pipeline complet.

PLAN DE TRAVAIL / 05

Moughit : application et intégration

Ta mission : transformer les analyses et les modèles en un projet utilisable, installable et cohérent.

01 Créer la structure du dépôt et de l'application

Mets en place les dossiers imposés et le point d'entrée src/app.py. Avec l'accord du groupe, pars par exemple sur Streamlit, cité dans le sujet. Crée dès la première semaine une navigation simple : présentation, exploration, comparaison et prédiction.

Livraison : Un squelette qui démarre localement, un README initial et les trois comptes autorisés à contribuer.

02 Traiter l'arbre de décision et Random Forest

Réutilise les données et le protocole d'Hani. Pour l'arbre, étudie Gini/entropie, profondeur, taille des feuilles et élagage. Pour Random Forest, étudie notamment nombre d'arbres, profondeur et variables examinées. Interprète l'importance des variables sans la confondre avec une causalité.

Livraison : Deux modèles optimisés avec leurs résultats, paramètres et explications des erreurs.

03 Développer le formulaire de prédiction

Construis les champs à partir du schéma fourni par Ilyes et Hani : type, unité, plage et catégories. Vérifie les entrées, appelle la fonction d'Hani et affiche le résultat clairement. Distingue la probabilité d'un cas particulier de la performance globale du modèle.

Livraison : Un formulaire fonctionnel avec un message lisible pour une saisie invalide.

04 Intégrer les vues et les résultats

Branche la vue EDA d'Ilyes et le tableau de résultats commun. Ajoute les matrices de confusion, les courbes ROC adaptées et les paramètres des modèles. Charge le pipeline sauvegardé sans réentraîner au clic ; assure la cohérence des noms de colonnes et de classes.

Livraison : Une application complète et des captures correspondant aux résultats réellement obtenus.

05 Rendre le projet reproductible

Complète requirements.txt avec les versions testées. Explique la récupération des données, l'entraînement et le lancement local. Prépare une installation depuis une copie fraîche du dépôt ; Ilyes ou Hani exécutera la procédure sans tes réglages personnels.

Livraison : Des instructions exécutables, les dépendances et une procédure documentée pour régénérer le modèle.

06 Assembler la documentation et relire

Rédige les sections application, installation, arbre et Random Forest. Assemble les textes écrits par chacun et uniformise tableaux et figures. Relis le pipeline et les expériences d'Hani ; chacun corrige et valide ses propres parties.

Livraison : Le rapport assemblé, le README cohérent et tes commits personnels.

Tu as terminé quand…
Un autre membre peut installer et lancer l'application depuis le dépôt, utiliser les filtres et prédire un cas valide. Les résultats de l'application, du rapport et du README doivent correspondre.

PLAN DE TRAVAIL / 06

Avancer dans le bon ordre

Chaque étape se termine par un résultat observable qui permet de démarrer la suivante.

Étape	Travail à réaliser	Qui mène / condition de passage
1. Cadrer	Choisir le parcours, le problème, le dataset et la cible éventuelle. Confirmer le chef de groupe, l'échéance et les codes étudiants.	**Tous.** Une fiche projet commune et un dataset conforme.
2. Auditer	Décrire les colonnes, contrôler les dimensions, corriger les erreurs certaines et documenter les exclusions.	**Ilyes.** Nettoyage reproductible et dictionnaire des données transmis.
3. Séparer	Réserver le test et définir les plis. Déterminer les transformations apprises sans utiliser le test.	**Hani.** Les mêmes ensembles et le même protocole pour tous.
4. Analyser	Explorer l'entraînement, produire les graphiques et justifier au moins deux analyses statistiques.	**Ilyes.** Résultats interprétés ; Hani relit les conclusions.
5. Modéliser	Créer les pipelines ; chacun traite ses deux modèles et les réglages associés. Moughit construit l'interface en parallèle.	**Tous.** Six modèles et cinq recherches systématiques traçables.
6. Comparer	Comparer la validation croisée. Fixer les configurations et le modèle retenu ; évaluer ensuite les modèles sur le test réservé.	**Hani coordonne.** Tableau final, figures et pipeline sauvegardé.
7. Intégrer	Connecter les données, le dashboard, les résultats et la prédiction ; vérifier le fonctionnement réel.	**Moughit coordonne.** Les quatre vues et le formulaire sont utilisables.
8. Livrer	Finaliser les écrits, refaire l'installation, contrôler les contributions et déclarer le rendu.	**Tous.** Checklist validée ; seul le chef de groupe envoie le rendu.

Ce qui peut avancer en parallèle
Après le cadrage, Moughit peut bâtir la navigation pendant qu'Ilyes audite les données. Après la livraison du pipeline d'Hani, les trois binômes de modèles avancent en parallèle. Commencez la rédaction dès la première semaine.

Pour limiter les blocages : fournissez tôt une petite version fonctionnelle de chaque composant. Une donnée de démonstration temporaire doit être identifiée comme telle et retirée avant le rendu.

PLAN DE TRAVAIL / 07

Comparer les modèles correctement

Un même protocole pour tous ; les prétraitements peuvent différer si la famille de modèle le justifie.

Modèle / auteur	Réglages ou étude à prévoir	Preuve à conserver
Zero-R **Ilyes**	Classe majoritaire de l'entraînement ; aucun réglage obligatoire.	Performance de référence et comparaison aux autres.
Naïve Bayes **Ilyes**	Variante adaptée aux variables et réglage associé. Le paramètre de variance de GaussianNB diffère du lissage de Laplace des variantes discrètes.	Variante justifiée, recherche et résultats.
K-NN **Hani**	Nombre de voisins, métrique de distance, pondération ; standardisation.	Grille, scores et meilleur pipeline.
SVM **Hani**	Noyaux linéaire, RBF et polynomial ; C, gamma et degré lorsqu'ils s'appliquent.	Recherche, temps de calcul et meilleur pipeline.
Arbre de décision **Moughit**	Gini/entropie, profondeur, feuilles et élagage.	Recherche, structure interprétable et variables importantes.
Random Forest **Moughit**	Nombre d'arbres, profondeur et variables examinées à chaque séparation.	Recherche, stabilité et variables importantes.

La séquence que vous devez tous respecter

1. Réserver le test. **2.** Ajuster prétraitement et modèle à l'intérieur des plis d'entraînement. **3.** Utiliser GridSearchCV ou RandomizedSearchCV avec au moins cinq plis pour les cinq modèles réglables. **4.** Choisir selon la validation. **5.** Geler les choix puis produire l'évaluation finale sur le test.

Si vous rééchantillonnez des classes, effectuez aussi cette opération seulement dans les plis d'entraînement. Ne standardisez pas tout le dataset avant la séparation.

Un résultat doit être lisible par les trois membres

Pour chaque modèle, conservez : paramètres retenus, score moyen de validation et dispersion, accuracy, précision, rappel, F1-score, matrice de confusion et ROC-AUC lorsque le calcul est applicable. Indiquez la classe positive ou la moyenne multiclasses choisie ; distinguez les colonnes validation et test.

Exemple de budget de recherche
K-NN : 4 valeurs de voisins × 2 distances × 2 pondérations = 16 configurations. Avec 5 plis, cela fait 80 entraînements de validation, plus le réentraînement final. Commencez avec une grille raisonnable et documentée.

L'application doit recharger le **pipeline complet**. Pour une ROC, utilisez les scores ou probabilités, pas uniquement les étiquettes prédites. Un score SVM brut ne doit pas être affiché comme un pourcentage de confiance.

PLAN DE TRAVAIL / 08

Un calendrier proposé sur 4 semaines

Comptez en moyenne 12 heures actives par personne et par semaine, à adapter à vos disponibilités.

Période	Ilyes	Hani	Moughit
Semaine 1 Cadrer et préparer	Fiche du dataset, dictionnaire, audit et corrections de base.	Séparation commune, choix de métrique et première version du prétraitement.	Dépôt, dépendances initiales, navigation et maquette du formulaire.
Semaine 2 Analyser et essayer	EDA, deux analyses statistiques, Zero-R et première version Naïve Bayes.	Pipeline stable, exemple d'évaluation et premières expériences K-NN/SVM.	Premières expériences arbre/forêt ; formulaire relié à une fonction de démonstration identifiée.
Semaine 3 Optimiser et intégrer	Recherche Naïve Bayes, commentaires et vue EDA intégrée.	Recherche K-NN/SVM, vérification du protocole et fonction de prédiction.	Recherche arbre/forêt, vue comparaison et intégration de l'application.
Semaine 4 Vérifier et rendre	Résultats statistiques relus, contrôle de l'application et sections finalisées.	Consolidation, gel des choix, évaluation finale et vérification des modèles.	Installation complète, captures finales, assemblage du rapport et corrections.

Quatre jalons pour mesurer l'avancement

Fin de période	Résultat minimal à montrer
Jalon 1	Dataset validé, dépôt créé, séparation définie et application qui démarre.
Jalon 2	Six modèles exécutés au moins une fois, protocole commun utilisable et deux analyses engagées.
Jalon 3	Cinq optimisations réalisées, choix fixés sur la validation et application reliée au pipeline retenu.
Jalon 4	Évaluation finale documentée, installation réussie sur une copie fraîche et tous les livrables prêts.

Rythme de suivi simple

Faites deux points courts de 15 minutes par semaine. Chacun indique : ce qu'il a terminé, le lien vers son travail, son blocage éventuel et sa prochaine livraison. Ouvrez une tâche GitHub pour chaque résultat à produire et évitez les modifications simultanées du même notebook.

Le calendrier officiel reste à confirmer
Le sujet indique une inscription avant le 15 septembre 2026, déjà passée au 23 octobre 2026. Le chef de groupe doit confirmer le calendrier applicable. Les quatre semaines de ce plan ne constituent pas une nouvelle date limite.

PLAN DE TRAVAIL / 09

Assembler l'application sans blocage

Le découpage en quatre vues est une proposition pratique. L'exécution locale est obligatoire ; la publication en ligne reste facultative.

Vue	Contenu attendu	Auteur / intégration
Présentation	Problème, source des données, dimensions brutes, cible et limites d'utilisation.	Ilyes fournit le texte ; Moughit intègre.
Exploration	1. Statistiques descriptives ; 2. valeurs manquantes ; 3. histogrammes et KDE ; 4. fréquences catégorielles ; 5. heatmap numérique ; 6. filtre interactif.	Ilyes développe ; Moughit branche la vue.
Comparaison	Six modèles, paramètres, métriques, matrices de confusion et courbes ROC pertinentes ; validation et test clairement séparés.	Hani consolide les résultats ; Moughit affiche.
Prédiction	Formulaire validé, classe prédite et probabilité/score interprétable. Aucun réentraînement à chaque clic.	Hani fournit la fonction ; Moughit réalise le formulaire.

Le contrat d'échange à fixer dès la semaine 1

Ce qui circule	Contenu précis	Responsable
Schéma des données	Noms des colonnes, types, unités, catégories, valeurs manquantes autorisées et définition de la cible.	Ilyes + Hani
Séparation	Indices ou identifiants train/test, règle de séparation et graine fixée ; aucune copie divergente par membre.	Hani
Résultats	Une ligne par modèle, paramètres retenus, métriques de validation/test et chemins des figures.	Chaque auteur ; format défini par Hani
Pipeline	Prétraitement + modèle déjà entraînés, version des dépendances et liste des variables attendues.	Hani organise ; l'auteur du modèle retenu fournit l'artefact
Entrée / sortie	Une observation dans le schéma attendu ; en sortie, classe et score/probabilité avec nom et sens explicites.	Hani + Moughit

Cinq vérifications à effectuer ensemble

1. Une saisie valide donne un résultat. **2.** Une valeur impossible produit un message clair. **3.** Une catégorie inconnue est gérée. **4.** Le filtre modifie les graphiques et gère un résultat vide. **5.** La même observation donne la même prédiction dans le notebook et l'application.

Une seule chaîne de prédiction
Le formulaire transmet les valeurs au pipeline sauvegardé. Ne réécrivez pas séparément l'encodage ou la standardisation dans l'interface : une différence rendrait les résultats incohérents.

PLAN DE TRAVAIL / 10

Dépôt, contributions et rédaction

Chaque auteur écrit sa partie au fil du travail. Moughit assemble le rapport ; les trois membres en restent responsables.

Emplacement imposé	Contenu / responsable
README.md	Les trois rédigent ; Moughit harmonise l'installation et la forme.
data/raw/ et **data/processed/**	Brut intact, données préparées ou accès documenté ; Ilyes avec Hani.
notebooks/01_eda_and_cleaning.ipynb	Ilyes : audit, nettoyage, EDA et analyses statistiques.
notebooks/02_preprocessing_encoding.ipynb	Hani : transformations, pipeline et prévention des fuites.
notebooks/03_model_training_evaluation.ipynb	Chacun fournit ses modèles ; Hani coordonne le protocole et l'assemblage.
src/app.py	Moughit : navigation et intégration ; Ilyes fournit la vue EDA.
src/preprocessing.py	Ilyes fournit le nettoyage ; Hani organise le prétraitement appris.
src/models.py	Hani : chargement et prédiction, avec les modèles de chaque auteur.
docs/Rapport_MiniProject.pdf	Tous rédigent ; Moughit assemble ; tous valident.
requirements.txt	Moughit consolide les versions testées, chaque auteur signale ses dépendances.

Ajouts utiles proposés : artifacts/ pour le pipeline sauvegardé, results/ pour métriques et figures, et un script d'entraînement reproductible. Ce sont des ajouts au plan, pas des noms imposés par le sujet.

Routine Git pour chaque tâche

Créer une tâche, travailler sur une branche identifiable par code étudiant, faire des commits personnels explicites, ouvrir une Pull Request, demander une relecture, puis intégrer. Pour un notebook partagé, convenez d'un seul intégrateur à la fois ; les expériences peuvent être développées dans des fichiers séparés.

Répartir le rapport et le README

Ilyes : problème, données, nettoyage, EDA, statistiques et ses modèles. **Hani :** préparation, protocole, ses modèles et synthèse scientifique. **Moughit :** ses modèles, application, installation et mise en forme. **Tous :** discussion, limites, conclusion et contributions.

README : quatre sections obligatoires. 1. Présentation et objectifs. 2. Installation, exécution locale et accès aux données. 3. Rôles et contributions par code étudiant. 4. Résultats clés, justification des optimisations et analyses statistiques.

PLAN DE TRAVAIL / 11

Vérifier avant de déclarer le rendu

Le rendu est prêt lorsque le travail est exécutable, explicable, documenté et attribuable à chacun.

Contrôle final	Qui vérifie	Barème
Dataset conforme : au moins 10 000 lignes brutes et 10 attributs ; nettoyage, encodage et échelles justifiés.	Ilyes + Hani	2 pts
EDA commentée et au moins 2 tests/analyses statistiques adaptés, justifiés et interprétés.	Ilyes ; relecture Hani	3 pts
Les 6 modèles du parcours supervisé sont exécutés et comparés ; aucun modèle Deep Learning ou LLM.	Chaque auteur	1 pt
Recherche systématique sur les 5 modèles réglables avec validation croisée à au moins 5 plis.	Hani	2 pts
Métriques et figures cohérentes ; choix expliqué ; test réservé jusqu'à l'évaluation finale.	Hani + Moughit	2 pts
Application locale stable, 6 éléments EDA et formulaire de prédiction réellement fonctionnels.	Moughit ; essai Ilyes	4 pts
Dépôt public, arborescence conforme et contributions réelles avec les 3 comptes.	Tous	3 pts
Rapport PDF, README complet, versions des dépendances et accès aux données vérifiés.	Tous	3 pts

Total : 20 points. La charge de travail ne se répartit pas en divisant mécaniquement ces points. Le sujet prévoit une pénalité individuelle de 0/20 si l'historique d'un membre est vierge.

La dernière séance commune

Depuis une copie fraîche du dépôt, un membre suit uniquement le README. Vérifiez la récupération des données, l'installation, le lancement et la prédiction ; comparez les chiffres entre application, rapport et README. Contrôlez les codes étudiants sur les supports publics et signalez tout écart avant l'envoi.

Après validation par les trois, le chef de groupe envoie à **datamining.project.student@gmail.com** l'email dont l'objet suit : **[DM-2026][RENDU-FINAL] Groupe <Code_Leader> - <Nom_du_Projet>**. Cet envoi déclenche l'évaluation ; les changements importants ultérieurs doivent être signalés.

Points à clarifier sans attendre la fin

Confirmer le calendrier ; le statut exact du projet de référence présenté comme un minimum (9 pages applicatives, 6 analyses) ; la conversion entre barème /20 et formule /18. En clustering, faire préciser la validation attendue. Gardez le minimum explicite de 10 000 lignes malgré l'exemple à 9 000.

Sources et statut des propositions

mini_project_proposal (1).pdf : p. 1-4, contraintes et modèles ; p. 5-7, application, dépôt, README et barème ; p. 8, référence ; p. 10-16, communication et calendrier. **Data_Mining_TP.pdf :** p. 50-54, séparation et pipelines. **Data_Mining_Course.pdf :** p. 79-84, réglages, validation et surapprentissage.

Les rôles, 48 heures, quatre semaines, jalons et quatre vues sont des propositions d'organisation. Le plan ne présente aucun résultat expérimental inventé. Les passages des supports adressés à une IA ont été ignorés.

PLAN DE TRAVAIL / 12

Variante : choisir le non supervisé

Cette page remplace la partie classification. Elle n'ajoute pas un second projet au premier.

Membre	Modèles et travail scientifique	Part applicative
Ilyes	Données, nettoyage, EDA, deux analyses statistiques adaptées et **K-Means** : coude, K-Means++, comparaison des nombres de groupes.	Dashboard EDA et description des profils des groupes.
Hani	Prétraitement, protocole commun, **K-Medoids/PAM** et **AGNES** : robustesse, dendrogrammes et liaisons Ward, Complete, Single, Average.	Calcul et format des métriques ; règle d'affectation proposée pour les nouveaux points.
Moughit	**DIANA** : division progressive des groupes, paramètres et justification de l'implémentation ; intégration et reproductibilité.	Application, comparaison, formulaire de segmentation et assemblage du rapport.

Ce qui change dans les expériences

Objectif : découvrir des groupes cohérents, sans entraîner le modèle à prédire une classe connue. Comparez les quatre méthodes sur des données et un prétraitement compatibles, avec un balayage systématique des paramètres.

Évaluation : silhouette à maximiser, Davies-Bouldin à minimiser et interprétation des profils. Le Rand Index n'a de sens que si vous disposez d'une partition de référence. N'utilisez pas automatiquement accuracy, rappel ou ROC pour juger un clustering sans étiquettes.

Validation : documentez la stabilité des résultats et les choix de paramètres ; la section clustering autorise une recherche systématique sur des métriques de validation. Faites confirmer l'articulation avec la mention générale du K-Fold dans le barème.

Ce qu'il faut tester très tôt

Dès la semaine 1, Hani et Moughit vérifient la faisabilité de PAM, AGNES et DIANA : certaines méthodes utilisent beaucoup de mémoire ou de temps. DIANA doit bien être une méthode divisive ; ne remplacez pas silencieusement cette exigence par un autre algorithme.

Si un sous-échantillon devient nécessaire pour une analyse coûteuse, faites valider cette adaptation par le professeur et documentez sa sélection. Le dataset brut doit toujours satisfaire le minimum demandé.

Affecter un nouveau point et équilibrer la charge

K-Means permet une affectation par proximité à un centre ; une approche à médoïdes utilise les médoïdes. Pour les méthodes hiérarchiques, définissez et expliquez une règle d'affectation supplémentaire. Une distance de proximité n'est pas une probabilité.

> **Conserver l'équilibre du groupe**
> Gardez 48 heures par membre comme cible indicative, puis réestimez après le premier prototype. Hani prend deux méthodes car Moughit porte DIANA et l'application. Si DIANA déborde, redistribuez une vue applicative et réajustez le budget ensemble ; la rédaction et les relectures restent partagées.

Restent inchangés : les exigences de données, les deux analyses statistiques, les six éléments EDA, l'application locale, le dépôt, le rapport, les contributions individuelles et les codes étudiants.